

Segundo Corte: Regresión lineal Múltiple

Andrés Martínez

2019

Índice

| | |
|--|----------|
| 1. Regresión Lineal Múltiple | 1 |
| 1.1. Supuestos | 1 |
| 1.2. Derivación de los Estimadores | 2 |
| 1.3. Propiedades de los Estimadores | 3 |
| 1.4. Colinealidad | 4 |
| 1.5. Goodness-of-fit | 5 |
| 1.6. Propiedades de los estimadores de mínimos cuadrados | 6 |
| 1.7. Ejemplo | 6 |
| 1.8. Inferencia del Modelo | 9 |
| 1.9. Revisando adentro de las matrices | 10 |
| 1.10. Significancia Global | 10 |
| 1.10.1. Ejemplo | 11 |
| 1.11. Predicción del modelo | 15 |

1. Regresión Lineal Múltiple

En un modelo lineal múltiple se asume que Y es una función lineal de sus predictores mas un ruido blanco:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots \beta_p X_p + \epsilon \quad (1)$$

1.1. Supuestos

1. Todos los parámetros son lineales
2. La muestra de n observaciones sigue el modelo poblacional del primer supuesto
3. No existe perfecta colinealidad
4. EL error tiene un valor esperado de cero dado por variables independientes.
5. Homocedasticidad: El error tiene la misma varianza que los valores de las variables explicativas.

No hacemos suposiciones sobre las distribuciones (marginales o conjuntas) de X_i , pero suponemos que $E[\epsilon|X] = 0$, $V[\epsilon|X] = \sigma^2$, y ese ϵ no está correlacionado entre las mediciones. La forma matricial del modelo es:

$$\mathbf{Y} = \mathbf{X}\beta + \epsilon \quad (2)$$

Donde \mathbf{X} incluye una columna inicial de 1.

Cuando se incluye se asume que este debe tener un comportamiento normal como se ve en la siguiente ecuación:

$$\epsilon \sim MVN(\mathbf{0}, \sigma^2 \mathbf{I}) \quad (3)$$

independiente de \mathbf{X} .

Los coeficientes se estiman de la siguiente forma:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} \quad (4)$$

Bajo el supuesto de ruido blanco, este es el mismo resultado que la estimación por máxima verosimilitud

$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\beta} = \mathbf{H}\mathbf{Y} \quad (5)$$

Donde $\mathbf{H} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$

Que es simétrico e idempotente. Los residuales se obtienen así:

$$SSE = \mathbf{Y}^T (\mathbf{I} - \mathbf{H}) \mathbf{Y} \quad (6)$$

donde $\mathbf{I} - \mathbf{H}$ es simétrico e idempotente

1.2. Derivación de los Estimadores

$$\hat{\beta}_{OLS} = \underset{\beta \in \mathbb{R}^2}{\operatorname{argmin}} (\mathbf{Y} - \mathbf{X}\beta)^T (\mathbf{Y} - \mathbf{X}\beta) \quad (7)$$

$$\frac{\partial}{\partial \beta} = (\mathbf{Y}^T \mathbf{Y} - 2\mathbf{Y}^T (\mathbf{X}\beta + \beta^T \mathbf{X}^T \mathbf{X}\beta)) \quad (8)$$

$$\frac{\partial}{\partial \beta} = -2\mathbf{X}^T \mathbf{Y} + 2\mathbf{X}^T \mathbf{X}\hat{\beta} = 0 \quad (9)$$

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} \quad (10)$$

1.3. Propiedades de los Estimadores

Insesgamiento del estimador mínimo cuadrado

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} \quad (11)$$

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X}^T (\mathbf{X} \beta + \epsilon) \quad (12)$$

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T \mathbf{X}) \beta \quad (13)$$

$$+ (\mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T \epsilon) \quad (14)$$

$$= \beta + (\mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T \epsilon) \quad (15)$$

$$E[\hat{\beta}|x] = \beta \quad (16)$$

Varianza de los errores estandar: Suponiendo Homocedasticidad

$$V[\hat{\beta}|\mathbf{X}] = V[\beta + (\mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T \epsilon)/\mathbf{X}] \quad (17)$$

$$V[\hat{\beta}|\mathbf{X}] = V[(\mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T \epsilon)/\mathbf{X}] \quad (18)$$

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} V[\mathbf{X}^T \epsilon/\mathbf{X}] (\mathbf{X}^T \mathbf{X})^{-1} \quad (19)$$

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T V[\epsilon/\mathbf{X}] \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \quad (20)$$

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \sigma^2 \mathbf{I} \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \quad (21)$$

$$\hat{\beta} = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \quad (22)$$

$$\hat{\beta} = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1} \quad (23)$$

Consistencia

- Ley de los grandes números
- Teorema Límite Central

Tenemos que $\hat{\beta} = \beta + (\mathbf{X}^T \mathbf{X})^{-1}(\mathbf{X}^T \epsilon)$ y se desea ver si $\hat{\beta}$ es consistente.
 $\lim_{n \rightarrow p} (\hat{\beta} - \beta) = 0$

Eficiencia: Bajo los supuestos de linealidad, muestreo aleatorio, no colinealidad perfecta, media condicional cero de los errores y homocedasticidad, $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$ es el mejor estimador lineal insesgado.

Además $\hat{\beta}_1 = \beta_1 + (\mathbf{X}_1^T \mathbf{X}_1)^{-1}(\mathbf{X}_1^T \epsilon_2)$.

1.4. Colinealidad

Asumiendo que $(\mathbf{X}^T \mathbf{X})^{-1}$ existe y es invertible o no singular, existen un número equivalente de condiciones para una matriz que debe ser invertible:

- Su determinante no es cero
- Su rango de columnas es completo, lo que quiere decir que todas las columnas son linealmente independientes.
- Su rango de filas es completo, lo que quiere decir que las filas son linealmente independientes.

Colinearidad perfecta:

Usando uno de los ejemplos del libro, que tiene la base de datos `vote1`, se hace una regresión entre los gastos de la campaña de A y B más los totales, con respecto a el voto de A.

```
> library(wooldridge)
> data("vote1")
> total=vote1$expendA +vote1$expendB
> model1=lm(vote1$voteA~ vote1$expendA+vote1$expendB+total)
> summary(model1)
```

Call:

```
lm(formula = vote1$voteA ~ vote1$expendA + vote1$expendB + total)
```

Residuals:

| | Min | 1Q | Median | 3Q | Max |
|--|----------|---------|--------|--------|---------|
| | -27.5661 | -8.6919 | 0.1641 | 9.0789 | 27.0131 |

Coefficients: (1 not defined because of singularities)

| | Estimate | Std. Error | t value | Pr(> t) |
|----------------|-----------|------------|---------|------------|
| (Intercept) | 49.618995 | 1.426147 | 34.79 | <2e-16 *** |
| vote1\$expendA | 0.038331 | 0.003387 | 11.32 | <2e-16 *** |
| vote1\$expendB | -0.036127 | 0.003107 | -11.63 | <2e-16 *** |

```

total          NA          NA          NA          NA
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11.58 on 170 degrees of freedom
Multiple R-squared:  0.5299,    Adjusted R-squared:  0.5244
F-statistic: 95.83 on 2 and 170 DF,  p-value: < 2.2e-16

El resultado evidencia que cuando existe colinealidad perfecta, no es posible
obtener el coeficiente para ese valor, porque este está directamente relacionado
con los gastos en A y B. Esto se abordará más adelante cuando se profundice
más en multicolinealidad.

> votop=1.2*vote1$voteA+rnorm(1)
> model2=lm(vote1$voteA~ vote1$expendA+vote1$expendB+votop)
> summary(model2)

Call:
lm(formula = vote1$voteA ~ vote1$expendA + vote1$expendB + votop)

Residuals:
    Min       1Q   Median       3Q      Max
-3.079e-13 -5.600e-16  1.694e-15  4.475e-15  4.816e-14

Coefficients:
              Estimate Std. Error  t value Pr(>|t|)
(Intercept)  -9.003e-01  8.769e-15 -1.027e+14 <2e-16 ***
vote1$expendA  1.617e-17  9.525e-18  1.698e+00  0.0914 .
vote1$expendB  7.629e-18  8.842e-18  8.630e-01  0.3895
votop          8.333e-01  1.357e-16  6.139e+15 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.458e-14 on 169 degrees of freedom
Multiple R-squared:  1,    Adjusted R-squared:  1
F-statistic: 2.672e+31 on 3 and 169 DF,  p-value: < 2.2e-16

```

Si no existe correlación perfecta, pero hay un alto grado de colinealidad como en el modelo 2, puede haber un problema de especificación probocando que los errores de los coeficientes aumenten. Para evitar la colinealidad entre las variables, se debe tener claro desde antes la relación entre las variables, pero también se deben probar los modelos de tal forma que los errores en los coeficientes sean mínimos y estas variables sean significativas.

1.5. Goodness-of-fit

El objetivo más importante de estos modelos es obtener los errores, pues permiten establecer la eficiencia del modelo y las posibles falencias de especifi-

cación que este pueda tener. Para esto definimos rapidamente los tres errores que siempre se buscan en una regresión lineal múltiple o simple:

$$SCT = \sum_{i=1}^n (y_i - \bar{y})^2 = \mathbf{Y}^T (\mathbf{I} - \mathbf{I}_{n \times n}) \mathbf{Y}. \quad (24)$$

$$SSE = \sum_{i=1}^n (y_i - \hat{y})^2 = \mathbf{Y}^T (\mathbf{I} - \mathbf{H}) \mathbf{Y}. \quad (25)$$

$$SSR = \sum_{i=1}^n (\hat{y} - \bar{y})^2 = \mathbf{Y}^T (\mathbf{H} - \mathbf{I}_{n \times n}) \mathbf{Y}. \quad (26)$$

Con estos resultados se puede obtener el coeficiente de determinación múltiple R^2 .

$$R^2 = \frac{SSR}{SCT} = 1 - \frac{SSE}{SCT}. \quad (27)$$


1.6. Propiedades de los estimadores de mínimos cuadrados

- $E[\hat{\beta}_i] = \beta_i$
- $V[\hat{\beta}_i] = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$
- Un estimado insesgado de σ^2 es $S^2 = SSE/[n - (k + 1)]$, donde $SSE = (\mathbf{Y} - \mathbf{X}\beta)^T (\mathbf{Y} - \mathbf{X}\beta)$
- Cada β_i está distribuido normalmente

1.7. Ejemplo

Usando el ejemplo 3.2 del libro de wooldrige, se hace la regresión del logaritmo de los salarios con respecto a la educación, la experiencia y el tiempo empleado. El proposito de obtener el logaritmo de los salarios es para generar una distribución simétrica y mejorar la escala.

```
> data("wage1")
> par(mfrow=c(1,2))
> hist(as.numeric(wage1$wage),breaks=20,main="",xlab="Salarios", col="red")
> lines(density(wage1$wage), col = 10)
> hist(as.numeric(wage1$lwage),breaks=20,main="",xlab="Salarios", col="blue")
> lines(density(wage1$lwage), col = 4)
>
>
```



La idea es trabajar con variables que tengan una distribución simétrica y al generar el logaritmo, los salarios adquieren una mejor forma como se ve en la gráfica anterior.

Para observar mejor el cambio, primero se hace la regresión con el logaritmo de los salarios, luego se hace con los salarios y se compara el resultado de cada uno de los coeficientes y el coeficiente de correlación

```
> modelo=lm(wage1$lwage~ wage1$educ+wage1$exper+wage1$tenure)
> summary(modelo)
```

Call:

```
lm(formula = wage1$lwage ~ wage1$educ + wage1$exper + wage1$tenure)
```

Residuals:

| Min | 1Q | Median | 3Q | Max |
|----------|----------|----------|---------|---------|
| -2.05802 | -0.29645 | -0.03265 | 0.28788 | 1.42809 |

Coefficients:

| | Estimate | Std. Error | t value | Pr(> t) | |
|---------------|----------|------------|---------|----------|-----|
| (Intercept) | 0.284360 | 0.104190 | 2.729 | 0.00656 | ** |
| wage1\$educ | 0.092029 | 0.007330 | 12.555 | < 2e-16 | *** |
| wage1\$exper | 0.004121 | 0.001723 | 2.391 | 0.01714 | * |
| wage1\$tenure | 0.022067 | 0.003094 | 7.133 | 3.29e-12 | *** |

```

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4409 on 522 degrees of freedom
Multiple R-squared:  0.316,    Adjusted R-squared:  0.3121
F-statistic: 80.39 on 3 and 522 DF,  p-value: < 2.2e-16

>
>

```

El segundo modelo es

```

> modelo1=lm(wage1$wage~ wage1$educ+wage1$exper+wage1$tenure)
> summary(modelo1)

Call:
lm(formula = wage1$wage ~ wage1$educ + wage1$exper + wage1$tenure)

Residuals:
    Min       1Q   Median       3Q      Max
-7.6068 -1.7747 -0.6279  1.1969 14.6536

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -2.87273     0.72896  -3.941 9.22e-05 ***
wage1$educ     0.59897     0.05128  11.679 < 2e-16 ***
wage1$exper    0.02234     0.01206   1.853  0.0645 .
wage1$tenure   0.16927     0.02164   7.820 2.93e-14 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.084 on 522 degrees of freedom
Multiple R-squared:  0.3064,    Adjusted R-squared:  0.3024
F-statistic: 76.87 on 3 and 522 DF,  p-value: < 2.2e-16

>

```

Como se puede ver el error en los coeficientes de cada variable aumenta, si bien el coeficiente de correlación aun no es óptimo para generar la regresión, si se puede ver una mejora cuando se trabaja con el logaritmo de los salarios.

Para continuar con el análisis se hace un gráfico qq plot de los residuales con el objetivo de observar cuál de los dos cumple con el supuesto de normalidad.

```

> library(car)
> par(mfrow=c(2,1))
> qqPlot(modelo1$residuals,main = "Salarios",ylab="Residuales")


```



```
[1] 15 229
```

```
> qqPlot(modelo$residuals,main = "Log Salarios",ylab="Residuales")
```

```
[1] 24 440
```



Al observar los residuales de ambos modelos, es mucho más claro que transformar la variable de salarios genera un mejor proceso de la regresión.

1.8. Inferencia del Modelo

Para generar la inferencia de cada uno de los estimadores, primero se hará el proceso de forma individual, y luego de forma global con la prueba F . En el test de significancia individual, se debe tener cuidado con las muestras pequeñas, dado que se puede rechazar la hipótesis nula H_0 cuando esta es cierta cayendo en error tipo uno. Para esto es mejor realizar una hipótesis a dos colas. De forma matricial el estadístico T se obtiene de la siguiente forma:

Usando la prueba t se obtiene que

$$T = \frac{\hat{\beta}_i - \beta_i}{S\sqrt{(\mathbf{X}^T\mathbf{X})^{-1}}} \quad (28)$$

Donde β_i corresponde al coeficiente que se está analizando. El error estandar es $S\sqrt{(\mathbf{X}^T\mathbf{X})^{-1}}$.

El intervalo para el coeficiente se obtiene con:

$$\hat{\beta}_i \pm T_{\alpha/2} S \sqrt{(\mathbf{X}^T \mathbf{X})^{-1}} \quad (29)$$

Recuerde que para que el coeficiente sea significativo este no puede pasar por cero.

1.9. Revisando adentro de las matrices

Para entender mejor que sucede en el modelo, recrearemos las matrices para un modelo de regresión lineal simple.

Primero revisamos $(\mathbf{X}^T \mathbf{X})$

$$(\mathbf{X}^T \mathbf{X}) = \begin{pmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix}$$

Como se puede ver en la matriz, en la posición $(1, 1)$ se encuentra el tamaño de la muestra, en la posición $(2, 2)$ se encuentra la suma de x al cuadrado y en las demás la suma de x . Solo cuando esta matriz tiene un determinante, se puede obtener la matriz inversa de $(\mathbf{X}^T \mathbf{X})$.

Con la matriz inversa se obtienen los calculos iniciales para encontrar las varianzas y covarianzas de cada uno de los coeficientes.

$$(\mathbf{X}^T \mathbf{X})^{-1} = \begin{pmatrix} \frac{\sum x_i^2}{n S_{xx}} & -\frac{\bar{x}}{S_{xx}} \\ -\frac{\bar{x}}{S_{xx}} & \frac{1}{S_{xx}} \end{pmatrix}$$

Como se vió en el primer corte, la diagonal de la matriz multiplicada por S^2 sirve para obtener la varianza de cada coeficiente, mientras que los demás valores deberían tender a cero ya que representan el primer cálculo de la covarianza, por lo tanto si existiera una relación entre las variables, se incumpliría el supuesto de independencia entre las variables generando colinealidad.

De acuerdo a lo anterior, $V(\hat{\beta}_0) = \frac{\sum x_i^2}{n S_{xx}} S^2$ y $V(\hat{\beta}_1) = \frac{1}{S_{xx}} S^2$ y con estos resultados se puede obtener el estadístico T para validar la significancia individual.

1.10. Significancia Global

Para encontrar la significancia global, se plantea la hipótesis $H_0 : \beta_{g+1} = \beta_{g+1} = \dots = \beta_k = 0$. La idea es encontrar un conjunto de parámetros que expliquen de forma conjunta la variable dependiente.

Para valorar el modelo se crea un modelo reducido para contrastarlo con el modelo completo.

$$\text{modeloR} : Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_g x_g + \epsilon \quad (30)$$

$$\text{modeloC} : Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_g x_g + \dots + \beta_k x_k + \epsilon \quad (31)$$

De esta forma se obtienen la suma de los errores SSE_r y SSE_c de cada modelo. Si el modelo completo aporta más información, SSE_c debería ser menor al SSE_r . Por lo tanto entre mayor sea la diferencia ($SSE_r - SSE_c$) más fuerte es la evidencia de que el modelo completo tiene más información y por lo tanto soporta la hipótesis alternativa a la planteada al principio de la sección.

Dado que estamos trabajando con la varianza y estamos haciendo una comparación de varianzas es conveniente trabajar con la distribución Chi cuadrado y con la distribución F .

Para cada suma de cuadrados se tiene las siguientes pruebas:

$$\chi_3^2 = \frac{SSE_r}{\sigma^2} \quad (32)$$

$$\chi_2^2 = \frac{SSE_c}{\sigma^2} \quad (33)$$

$$\chi_1^2 = \frac{SSE_r - SSE_c}{\sigma^2} \quad (34)$$

Recuerde que la función χ^2 trabaja con grados de libertad. Por lo tanto los grados de libertad para cada muestra son $(n - [g + 1])$, $(n - [k + 1])$ y $(k - g)$ respectivamente.

Comparando las dos distribuciones se crea la prueba F y se obtiene el estadístico para determinar se debe o no rechazar la hipótesis nula,

$$F = \frac{\chi_1^2 / (k - g)}{\chi_2^2 / (n - [k + 1])} \quad (35)$$

1.10.1. Ejemplo

Realice una regresión lineal usando las matrices con dos variables independientes. Donde $X_1 = -2, -1, 0, 1, 2$, $X_2 = 4, 1, 0, 1, 4$ y $Y = 0, 0, 1, 1, 3$.

```
> Y=as.vector(c(0,0,1,1,3))
> X=matrix(c(1,1,1,1,1,-2,-1,0,1,2,4,1,0,1,4),nrow=5,ncol=3)
> X
```

```

      [,1] [,2] [,3]
[1,]    1   -2    4
[2,]    1   -1    1
[3,]    1    0    0
[4,]    1    1    1
[5,]    1    2    4

> Beta=solve(t(X)%*%X)%*%t(X)%*%Y
> Beta

      [,1]
[1,] 0.5714286
[2,] 0.7000000
[3,] 0.2142857

> SSE=t(Y-X)%*%Beta)%*%(Y-X)%*%Beta)
> SSE

      [,1]
[1,] 0.4571429

> S2=SSE/(5-3)
> S2

      [,1]
[1,] 0.2285714

> VB=solve(t(X)%*%X)
> VB

      [,1] [,2] [,3]
[1,] 0.4857143 0.0 -0.14285714
[2,] 0.0000000 0.1 0.00000000
[3,] -0.1428571 0.0 0.07142857

> VB0=S2*VB[1,1]
> VB0

      [,1]
[1,] 0.1110204

> VB1=S2*VB[2,2]
> VB1

      [,1]
[1,] 0.02285714

> VB2=S2*VB[3,3]
> VB2

```

```

[1,]
[1,] 0.01632653

>

> T0=Beta[1]/sqrt(VB0)
> T0

[1,]
[1,] 1.714986

> T1=Beta[2]/sqrt(VB1)
> T1

[1,]
[1,] 4.630065

> T2=Beta[3]/sqrt(VB2)
> T2

[1,]
[1,] 1.677051

> ## Buscar el test de dos colas por ser una muestra pequeña
> pb0=2*pt(-abs(T0),df=4, lower.tail = TRUE)
> pb0

[1,]
[1,] 0.1614951

> pb1=2*pt(-abs(T1),df=4)
> pb1

[1,]
[1,] 0.009806739

> pb2=2*pt(-abs(T2),df=4)
> pb2

[1,]
[1,] 0.1688381

> # Modelo reducido
> XR=X[,1]
> Beta=solve(t(XR)%*%XR)%*%t(XR)%*%Y
> Beta

[1,]
[1,] 1

```

```

> SSER=t(Y-XR%*%Beta)%*%(Y-XR%*%Beta)
> SSER

      [,1]
[1,]      6

>

> F=((SSER-SSE)/(2-0))/(SSE/(5-3))
> F

      [,1]
[1,] 12.125

> FAOV <- aov(Y~X[,2]+X[,3])
> FAOV

Call:
aov(formula = Y ~ X[, 2] + X[, 3])

Terms:
              X[, 2]   X[, 3] Residuals
Sum of Squares  4.900000 0.642857 0.457143
Deg. of Freedom      1         1         2

Residual standard error: 0.4780914
Estimated effects may be unbalanced

>

      Coeficiente de Correlación

> R2=1-SSE/(t(Y)%*%Y)
> R2

      [,1]
[1,] 0.9584416

> modelm=lm(Y~X[,2]+X[,3])
> summary(modelm)

Call:
lm(formula = Y ~ X[, 2] + X[, 3])

Residuals:
      1      2      3      4      5
-0.02857 -0.08571  0.42857 -0.48571  0.17143

```

```

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   0.5714     0.3332   1.715   0.2285
X[, 2]        0.7000     0.1512   4.630   0.0436 *
X[, 3]        0.2143     0.1278   1.677   0.2355
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4781 on 2 degrees of freedom
Multiple R-squared:  0.9238,    Adjusted R-squared:  0.8476
F-statistic: 12.13 on 2 and 2 DF,  p-value: 0.07619

> FAOV<- anova(modelm)
> FAOV

Analysis of Variance Table

Response: Y
              Df Sum Sq Mean Sq F value  Pr(>F)
X[, 2]         1  4.9000   4.9000  21.4375 0.04362 *
X[, 3]         1  0.6429   0.6429   2.8125 0.23553
Residuals      2  0.4571   0.2286
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

1.11. Predicción del modelo

La predicción de un modelo varía de acuerdo a la transformación de las variables que se usaron para generar el modelo estimado. No obstante para determinar el valor de la predicción se obtienen los intervalos de confianza que permite establecer el valor esperado y la variación con respecto a la media de la variable que se desea estimar.